IA Neurossimbólica para Perguntas e Respostas sobre Modelos Metabólicos em Escala Genômica: um Estudo Comparativo entre RAG Vetorial, GraphRAG e OG-RAG

Giovani Tavares
giovanitavares@usp.br

Universidade de São Paulo — 21 de Julho de 2026

1 Resumo

Sistemas de *Retrieval-Augmented Generation* (RAG) combinam grandes modelos de linguagem (LLMs) com mecanismos de recuperação de informação capazes de integrar um conjunto de documentos pertinentes a uma ou mais especialidades. Quando testados em domínios de conhecimento específicos, tais mecanismos se baseados exclusivamente em similaridade vetorial podem apresentar limitações conhecidas na literatura como a recuperação de contextos semanticamente próximos às entradas do sistema, porém nem sempre factualmente pertinentes a ela. No mesmo tipo de teste, a busca vetorial frequentemente falha em recuperar todos os documentos pertinentes à entrada. Essas limitações estão relacionadas a piora na confiabilidade dos textos e respostas gerados por esses sistemas, o que pode ser verificado por métricas como *context recall* e *answer correctness*.

Visando minimizar esses problemas, trabalhos recentes relatam ganhos consistentes nessas métricas ao integrar uma camada de representação simbólica do conhecimento (ontologias e grafos) no processo de recuperação do RAG, propondo arquiteturas que podem ser incluídas no que se denomina IA Neurossimbólica [8]. Dentre elas, o OG RAG [9] demonstrou tais ganhos nos domínios de agricultura e jornalismo, enquanto o [3] o fez no contexto da biomedicina. Há ainda aplicações nos contextos jurídico-regulatórias e *compliance* financeiro. Este projeto investiga se os mesmos efeitos se replicam no domínio de modelos metabólicos em escala genômica (*genome-scale metabolic models*, GEMs), propondo um estudo comparativo controlado entre três arquiteturas: RAG com puro, GraphRAG e OG-RAG. Elas serão instanciadas sobre a ontologia de domínio OntoGEM [10] e sobre dados do repositório BiGG Models [5], com foco no modelo *E. coli core*. A hipótese central é que a inclusão da camada simbólica melhora as métricas baseadas no *framework* RAGAS [2] neste domínio. Para testá-la, será construído um conjunto anotado de perguntas de competência e respostas sobre o modelo metabólico citado com o apoio de especialistas. Essas perguntas serão pré-classificadas por tipo de explicação exigida para respondê-las, com respostas de referência derivadas dos modelos extraídos da própria base BiGG. As três arquiteturas serão avaliadas sob condições controladas (mesmo LLM gerador, mesmo conjuntos de GEMs fonte, variando apenas o mecanismo de recuperação), visando ao isolamento do efeito da estrutura simbólica sobre métricas do RAGAS. Espera-se produzir evidência empírica, ainda que restrita a este domínio e modelo, sobre o papel da representação simbólica do conhecimento na melhoria das métricas citadas, além de fornecer um conjunto de perguntas e respostas anotado e verificado por especialistas sobre o modelo *E. coli core*.

2 Introdução e Justificativa

2.1 Contextualização

Sistemas de *Retrieval-Augmented Generation* [6] tornaram-se a abordagem dominante para reduzir alucinações e ancorar respostas de LLMs em fontes verificáveis, recuperando trechos de um corpus externo por similaridade vetorial e condicionando a geração da resposta a esse contexto via engenharia de *prompt*. Entretanto, ao basear a camada de recuperação de informação em somente busca vetorial, métricas que avaliam a qualidade do sistema definidas no RAGAS [2] tendem a ser insatisfatórias. Dentre outras causas, o prejuízo a essas métricas se deve à recuperação de amostras de documentos semanticamente próximos à pergunta mas irrelevantes a ela ou mesmo contraditórios em relação aos fatos que os especialistas de domínio estabelecem como corretos. Esses efeitos não são tratáveis apenas com a busca vetorial e, portanto, alternativas que permitam integrar a representações simbólicas do conhecimento validadas por especialistas a arquiteturas de RAG tem-se demonstrado promissora em diferentes domínios [9] [3].

Os sistemas resultantes de tal integração podem ser classificados no que denomina Inteligência Artifical Neurossimbólica [8], uma vez que integram a capacidade de aprendizado e percepção das redes neurais (LLMs, nesse caso) à capacidade de raciocínio lógico e interpretável da representação simbólica do conhecimento. Além das melhorias em métricas como *context recall*, *answer similarity* e *answer correctness* [2], sistemas neurossimbólicos como o OG RAG [9] são dotados de maior explicabilidade e rastreabilidade estrutural quando comparados ao RAG puramente vetorial. Isso se justifica pela integração de ontologias ao processo de recuperação de informação do RAG proposta em [9], o que permite que cada fato recuperado carregue a relação semântica que o liga à pergunta. A busca vetorial pura, por sua vez, relaciona o fato à pergunta com métricas de similaridade vetorial de pouca ou baixa interpretabilidade por seres humanos.

2.2 Bibliografia

O *framework* RAGAS [2] formalizou a avaliação de arquiteturas de RAG por meio de métricas derivadas automaticamente da tripla pergunta-resposta-contexto, entre as quais se destacam *faithfulness* (grau em que a resposta é sustentada pelo contexto recuperado), *context precision* e *context recall* (adequação e completude do contexto recuperado em relação à resposta de referência) e *answer relevancy*. Por não depender de anotação humana exaustiva a cada execução, o RAGAS tornou-se referência para comparação de arquiteturas de RAG e é adotado, direta ou indiretamente, pelos trabalhos discutidos a seguir.

Sharma et al. propõem o OG-RAG (*Ontology-Grounded RAG*) [9], no qual uma ontologia de domínio é usada como esquema de extração e recuperação (o que os autores chamam de Modo A), estruturando o corpus em fatos compatíveis com a ontologia antes da indexação; os autores relatam ganhos nas seguintes métricas inspiradas no RAGAS nos domínios de agricultura e jornalismo:

1. **Context Recall (C-Rec):** Proporção de afirmações da resposta de referência que podem ser atribuídas às informações presentes no contexto recuperado.
2. **Context Entity Recall (C-ERec):** Proporção de entidades da resposta de referência que estão presentes no contexto recuperado.
3. **Answer Similarity (A-Sim):** Similaridade entre a resposta gerada e a resposta de referência no espaço de *embeddings*.
4. **Answer Correctness (A-Corr):** Combinação da *answer similarity* (definida acima) com a similaridade factual, que corresponde ao *F1-score* entre as afirmações da resposta de referência e as da resposta gerada.
5. **Answer Relevance (A-Rel):** Mede a facilidade com que a pergunta original pode ser inferida a partir da resposta gerada.

Feng et al. [3] oferecem um exemplo concreto dessa integração no domínio biomédico com o OntologyRAG, voltado ao mapeamento de códigos entre ontologias clínicas (como ICD-9-CM, ICD-10-CM e SNOMED CT). Os autores convertem as ontologias e seus mapeamentos em grafos de conhecimento RDF e empregam um módulo que traduz perguntas em linguagem natural para consultas SPARQL, recuperando o contexto que será adicionado à entrada da LLM para gerar as respostas. Feng et al. [3] demonstram que os LLMs têm desempenho insuficiente na tarefa quando geram tais respostas sem o conhecimento

estruturado da ontologia. Além disso, por manter o conhecimento no grafo, tal abordagem assim como a OG RAG [9] permite refletir atualizações frequentes dos conhecimentos do domínio biomédico representados nas ontologias sem a necessidade de retreinar o LLM. Ambas arquiteturas também viabilizam maior interpretabilidade das respostas geradas. Por definirem explicitamente conceitos, entidades e as relações entre eles, as ontologias oferecem uma representação simbólica sobre a qual a inferência realizada pelo LLM pode ser rastreada passo a passo, de modo que cada conclusão seja atribuível aos fatos e relações representados nas ontologias e que foram curados por seres humanos.

O GraphRAG [1] representa uma outra família de arquiteturas neurossimbólicas, na qual a representação simbólica de conhecimento não é uma ontologia curada por especialistas, mas um grafo de entidades e relações extraído automaticamente do corpus de documentos de domínio por um LLM, posteriormente utilizado para sumarização hierárquica e recuperação. Essa distinção é relevante para o presente projeto: GraphRAG e OG-RAG compartilham o uso de uma camada estruturada intermediária entre o corpus e a geração, mas diferem quanto à origem e à validação dessa estrutura. Enquanto ela é extraída automaticamente pelo LLM no GraphRAG, no OG RAG ela é curada e validada por especialistas de domínio. Dessa forma, ao comparar essas duas arquiteturas contra um baseline vetorial não só verifica se *alguma* estrutura simbólica melhora as métricas do RAGAS, mas também avalia se a origem e o grau de curadoria humana dessa estrutura importam.

A camada simbólica curada utilizada neste trabalho é a ontologia OntoGEM, desenvolvida por Souza [10] em seu projeto de doutorado do mesmo grupo de pesquisa. O trabalho de Souza propõe uma ontologia de domínio específica para Modelos Metabólicos de Escala Genômica (GEMs), formalizada a partir de perguntas de competência formadas junto a especialistas de biologia de sistemas e estruturada segundo etapas de engenharia de ontologias: especificação, conceitualização, formalização e implementação. O objetivo original dessa ontologia é acelerar e melhorar a qualidade do processo de reconstrução de GEMs, viabilizando a integração e reconciliação de dados provenientes de múltiplas bases biológicas (como BiGG, KEGG e ChEBI). Embora a motivação original da OntoGEM seja a reconstrução de modelos metabólicos, e não a melhoria da recuperação de informação em sistemas de RAG como no presente trabalho, a formalização das entidades e relações de um GEM (reações, metabólitos, genes, complexos enzimáticos, compartimentos celulares) desenvolvidas por Souza [10] resultantes na ontologia OntoGEM a torna diretamente reaproveitável para a arquitetura OG-RAG neste projeto, dispensando a necessidade de desenvolver uma nova ontologia de domínio do zero.

Em conjunto, esses trabalhos sugerem um padrão consistente de ganhos relacionados à integração de representações simbólicas de conhecimentos de domínio às camadas de recuperação de informação de arquiteturas de RAG. Por outro lado, nenhum desses domínios possui a característica central do domínio de modelos metabólicos em escala genômica (GEMs). Não há, até onde este projeto pôde levantar, evidência publicada sobre o efeito de camadas simbólicas em RAG aplicado a esse domínio.

2.3 O Domínio de Aplicação: Modelos Metabólicos em Escala Genômica

O processo de construção de um modelo computacional do metabolismo de um organismo é conhecido como reconstrução, enquanto o modelo resultante é frequentemente denominado modelo metabólico em escala genômica (GEM) [10]. O repositório BiGG Models [5] disponibiliza GEMs curados e padronizados, entre os quais o modelo *E. coli core*, um subconjunto didático e amplamente utilizado do metabolismo central de *Escherichia coli*, adequado à construção de um conjunto controlado de perguntas de domínio por combinar cobertura representativa das entidades do modelo (reações, metabólitos, genes, compartimentos) com um tamanho factível para anotação por especialistas durante o período de mestrado.

A ontologia OntoGEM, desenvolvida em [10], formaliza as entidades e relações de um GEM, sendo elas as reações, metabólitos, genes, complexos enzimáticos, compartimentos celulares e as relações estequiométricas e regulatórias entre eles. Dessa forma, pretende-se utilizar essa ontologia como o esquema de extração e recuperação da arquitetura OG-RAG.

2.4 Lacuna e Motivação

Não há evidência de que os ganhos reportados para RAG neurossimbólicos em diferentes domínios também se aplicam ao domínio de perguntas e respostas relacionados a GEMs. Além disso, os trabalhos revisados comparam arquiteturas neurossimbólicas a baselines puramente vetoriais, mas raramente isolam o efeito específico da camada simbólica de outras variáveis do pipeline (modelo gerador, corpus, estratégia de *chunking*), o que limita a atribuição causal dos ganhos observados. Este projeto propõe um desenho

experimental controlado que mantém fixos o LLM gerador e o corpus-fonte, variando apenas o mecanismo de recuperação (vetorial puro, GraphRAG, OG-RAG), de modo a isolar o efeito da representação simbólica do conhecimento sobre as métricas do RAGAS.

3 Objetivos

3.1 Objetivo Geral

Demonstrar o efeito positivo da inclusão da representação simbólica do conhecimento em diferentes arquiteturas de RAG sobre as métricas do RAGAS [2], no domínio de modelos metabólicos em escala genômica.

3.2 Objetivos Específicos

1. Construir, com apoio de especialistas de domínio, um conjunto anotado de perguntas de competência sobre o modelo metabólico *E. coli core*, pré-classificado por tipo de explicação exigida, com respostas de referência derivadas de forma reprodutível a partir do repositório BiGG Models.
2. Formalizar a ontologia OntoGEM como esquema de extração e recuperação (Modo A [9]) para uso nas arquiteturas OG-RAG.
3. Implementar três pipelines de RAG comparáveis — vetorial puro (*baseline*), GraphRAG e OG-RAG — operando sobre o mesmo corpus-fonte e o mesmo modelo gerador, variando apenas o mecanismo de recuperação.
4. Avaliar as três arquiteturas segundo as métricas do RAGAS (*faithfulness*, *context precision*, *context recall* e *answer relevancy*) sobre o conjunto de perguntas construído.
5. Analisar estatisticamente se as diferenças observadas entre arquiteturas com e sem camada simbólica são significativas, e se o padrão de ganhos (concentração em *faithfulness* e *context recall*) reportado na literatura de outros domínios se replica no domínio de GEMs.
6. Discutir, a partir dos resultados, os limites de generalização das evidências obtidas para modelos e domínios distintos do estudado.

4 Plano de Trabalho e Cronograma de Execução

O projeto está organizado em seis fases, detalhadas a seguir, executadas ao longo de 24 meses.

1. **Revisão bibliográfica.** Consolidação da revisão sistemática sobre RAG neurossimbólico, arquiteturas de recuperação estruturada (OG-RAG, GraphRAG) e literatura de avaliação (RAGAS).

2. **Refinamento da OntoGEM para os frameworks de RAG e exame de qualificação.** Adaptação técnica da ontologia OntoGEM [10] — cuja formalização conceitual é resultado do trabalho de Souza [10] — para os formatos e esquemas exigidos pelos *frameworks* de RAG utilizados (por exemplo, conversão da OWL para o esquema de extração/recuperação do OG-RAG Modo A), sem alterar sua estrutura conceitual original. Em paralelo, realização do exame de qualificação.

3. **Construção do dataset anotado de perguntas de domínio e implementação das arquiteturas de RAG.** Elaboração, em conjunto com especialistas em biologia de sistemas/metabolismo, de um conjunto de perguntas de competência sobre o modelo *E. coli core*, com classificação por tipo de explicação e construção de respostas de referência (detalhado na Seção 5.2). Em paralelo, desenvolvimento dos três pipelines de RAG (vetorial puro, GraphRAG, OG-RAG Modo A) sobre corpus comum derivado do BiGG Models e da OntoGEM adaptada.

4. **Execução dos experimentos e coleta de métricas.** Execução das três arquiteturas sobre o conjunto de perguntas, coleta das métricas RAGAS e dos artefatos intermediários (contextos recuperados, respostas geradas).

5. **Análise dos resultados, redação e defesa.** Análise estatística comparativa entre arquiteturas, análise por tipo de pergunta, redação da dissertação e defesa final.

Atividade	**T1**	**T2**	**T3**	**T4**	**T5**	**T6**	**T7**	**T8**
Revisão bibliográfica	X	X						
Refinamento da OntoGEM para os frameworks de RAG			X	X				
Exame de qualificação			X	X				
Construção do dataset anotado (especialistas)				X	X			
Implementação das arquiteturas de RAG (vetorial, GraphRAG, OG-RAG)				X	X			
Execução dos experimentos e coleta de resultados (RAGAS)						X		
Análise estatística dos resultados							X	
Redação da dissertação							X	X
Defesa da dissertação								X

Nota: T1–T8 referem-se a trimestres consecutivos ao longo de 24 meses.

5 Material e Métodos

5.1 Desenho Experimental

O estudo adota um desenho comparativo de três fases, no qual a variável manipulada é exclusivamente o mecanismo de recuperação, mantendo-se fixos o LLM gerador, o corpus-fonte e o conjunto de perguntas de avaliação, de modo a isolar o efeito da representação simbólica do conhecimento sobre as métricas do RAGAS:

- **Fase A — RAG vetorial (baseline).** Indexação do corpus textual derivado do BiGG Models por *embeddings* densos, com recuperação por similaridade de cosseno, sem qualquer estrutura simbólica intermediária. Representa o estado da arte sem integração de conhecimento estruturado.
- **Fase B — GraphRAG [1].** Extração automática, via LLM, de um grafo de entidades e relações a partir do mesmo corpus, com sumarização hierárquica de comunidades e recuperação orientada pelo grafo. A estrutura simbólica não é curada por especialistas, mas induzida a partir dos dados.
- **Fase C — OG-RAG, Modo A [9].** Uso da ontologia OntoGEM [10] como esquema de extração e recuperação: o corpus é estruturado em fatos compatíveis com as classes e relações da ontologia antes da indexação, e a recuperação é restringida pelo esquema ontológico. Única fase com estrutura simbólica curada e validada por especialistas de domínio (Modo A, conforme operacionalização de [9]; os Modos B — vocabulário de *prompt* — e C — validador *a posteriori* — não são objeto deste estudo).

As três fases utilizarão o mesmo modelo gerador (LLM), a mesma estratégia de *prompt* de geração de resposta final (variando apenas o contexto recuperado) e o mesmo corpus-fonte, derivado do modelo *E. coli core* do repositório BiGG Models.

5.2 Construção do Dataset Anotado de Perguntas de Domínio

Um dos pilares metodológicos do projeto é a construção, junto a especialistas de domínio (pesquisadores da área de biologia de sistemas/modelagem metabólica), de um conjunto anotado de perguntas de competência sobre o modelo *E. coli core*. Essa etapa seguirá o seguinte protocolo:

1. **Reaproveitamento das perguntas de competência.** As perguntas de competência utilizadas neste projeto são as já elicitadas e formuladas no âmbito do trabalho de Souza [10], que cobrem consultas sobre metabólitos, reações e topologia da rede (por exemplo, estequiometria de reações, direcionalidade, genes associados via regras GPR, compartimentalização e vias metabólicas). Não há, portanto, uma nova etapa de elicitação de perguntas junto a especialistas neste projeto.
2. **Seleção das reações para instanciação das perguntas.** Diversas perguntas de competência são parametrizadas em termos de uma reação genérica R (ou de outras entidades genéricas do modelo), exigindo a seleção de instâncias concretas do modelo *E. coli core* para gerar as perguntas efetivamente utilizadas na avaliação. Essa seleção considerará (i) a dificuldade esperada da pergunta em função da reação escolhida (por exemplo, reações com múltiplas isoformas enzimáticas ou regras GPR complexas tendem a gerar perguntas mais difíceis do que reações com associação gene-reação simples) e (ii) a quantidade de instanciações necessária para garantir cobertura representativa das entidades e relações do modelo em cada categoria de pergunta.
3. **Reaproveitamento da classificação por tipo de explicação.** As perguntas de competência de Souza [10] já são acompanhadas de uma classificação por categoria de explicação, definida independentemente da execução deste projeto, o que evita classificações *post hoc* e o viés de confirmação associado. As categorias reaproveitadas são: *reaction provenance*, *metabolite provenance*, *model provenance*, *biological evidence*, *model assumptions*, *model validation*, *network structure*, *semantic classification*, *conflict management* e *accountability*. Essa classificação será utilizada diretamente como base para a análise estratificada dos resultados por categoria.
4. **Construção de respostas de referência (*gold answers*).** As respostas de referência serão construídas em duas etapas: (i) busca e extração dos dados correspondentes diretamente na API do BiGG

Models para cada instância selecionada, garantindo rastreabilidade entre cada resposta de referência e o dado-fonte correspondente; (ii) sessões de validação com especialistas de domínio para conferência e, quando necessário, correção das respostas obtidas.

5. **Pré-registro de hipóteses por categoria.** Dentre as categorias de pergunta reaproveitadas de Souza [10], aquelas nas quais se espera maior efeito da camada simbólica (por exemplo, *network structure*, *reaction provenance* e *metabolite provenance*, que dependem mais fortemente de restrições estruturais do modelo) serão declaradas antes da execução dos experimentos, permitindo uma análise confirmatória dessas categorias específicas, além da análise exploratória das outras.

O conjunto resultante — da ordem de dezenas de perguntas de competência, dimensionado para cobertura representativa das entidades e relações do modelo *E. coli core* — constitui o instrumento de avaliação comum às três fases experimentais.

5.3 Corpus e Recursos de Domínio

- **Fonte de dados:** modelo *E. coli core*, obtido do repositório BiGG Models [5], contendo reações, metabólitos, genes e regras de associação gene-proteína-reação (GPR).
- **Ontologia de domínio:** OntoGEM, desenvolvida em [10], formalizando classes e relações estequiométricas e regulatórias do modelo, utilizada como esquema de extração/recuperação na Fase C.
- **Corpus textual comum:** representação em linguagem natural (formato *markdown*) do modelo *E. coli core*, gerada de forma determinística a partir dos dados estruturados do BiGG Models, garantindo que os três braços operem sobre o mesmo conteúdo informacional.

5.4 Implementação

As três arquiteturas serão implementadas com bibliotecas de código aberto de referência para cada abordagem (RAG vetorial, GraphRAG e OG-RAG), com o mesmo modelo de linguagem utilizado como gerador em todas as fases, de modo a evitar que diferenças de capacidade do LLM confundam o efeito da variável de interesse. Parâmetros comuns entre arquiteturas (tamanho de *chunk*, número de documentos recuperados *top-k*, temperatura de geração) serão mantidos constantes sempre que a arquitetura permitir.

6 Forma de Análise dos Resultados

6.1 Métricas

Para cada par (pergunta, arquitetura), serão calculadas as métricas do RAGAS [2]: *faithfulness*, *context precision*, *context recall* e *answer relevancy*. As distribuições dessas métricas serão comparadas entre as três fases experimentais.

6.2 Testes Estatísticos

Como cada pergunta do conjunto de avaliação criado será respondida pelas três arquiteturas, a comparação entre elas será feita a partir da diferença de cada métrica, pergunta a pergunta, entre uma arquitetura com camada simbólica (GraphRAG ou OG-RAG) e o baseline vetorial. Para testar se essas diferenças são estatisticamente significativas, será utilizado o teste de Wilcoxon signed-rank, uma alternativa não paramétrica ao teste t pareado. A escolha por um teste não paramétrico se justifica porque as métricas do RAGAS são limitadas ao intervalo $[0, 1]$, o que tende a produzir distribuições assimétricas ou concentradas nas extremidades, violando a suposição de normalidade exigida pelos testes paramétricos. Como o p-valor depende fortemente do tamanho da amostra e não indica, por si só, a magnitude da diferença observada, os resultados dos testes serão complementados por uma medida de tamanho de efeito (a correlação *rank-biserial* pareada), permitindo distinguir diferenças estatisticamente significativas mas pouco relevantes na prática de diferenças de fato substanciais entre arquiteturas. Essa distinção é fundamental neste trabalho dado o tamanho moderado do conjunto de perguntas de avaliação que será criado.

6.3 Análise Estratificada por Tipo de Pergunta

Consistente com o pré-registro das categorias de pergunta (Seção 5.2-e), os resultados serão analisados também de forma estratificada por tipo de explicação exigida, permitindo testar especificamente a hipótese de que o efeito da camada simbólica é mais pronunciado em perguntas relacionais/multi-*hop*, nas quais a estrutura da ontologia atua como restrição sobre o espaço de recuperação.

6.4 Análise Qualitativa

Uma amostra de casos em que as arquiteturas divergem substancialmente em *faithfulness* ou *context recall* será inspecionada qualitativamente, com o objetivo de caracterizar os mecanismos pelos quais a estrutura simbólica altera o contexto recuperado.

6.5 Critérios de Confirmação/Refutação da Hipótese

A hipótese de que a inclusão da camada de representação simbólica do conhecimento melhora as métricas do RAGAS no domínio de GEMs será considerada válida se as fases com estrutura simbólica (GraphRAG e/ou OG-RAG) apresentarem ganhos estatisticamente significativos frente ao baseline vetorial, concentrados nas métricas de *faithfulness* e *context recall*, replicando o padrão relatado na literatura de outros domínios [3, 4, 7, 9]. A comparação entre as Fases B e C permitirá discutir se o grau de curadoria da estrutura simbólica (induzida no GraphRAG versus validada por especialistas em OG RAG) influencia a magnitude dos ganhos observados.

6.6 Resultados Esperados

Espera-se demonstrar que a representação simbólica do conhecimento é responsável pela melhoria de métricas relacionadas a sistemas de perguntas e respostas baseados em RAG, fornecendo evidência sobre a importância de integrar camadas de conhecimento validadas, compreensíveis, auditáveis e editáveis por especialistas de domínio em arquiteturas até então baseadas exclusivamente em aprendizado de máquina — das quais o RAG por busca vetorial pura é o principal exemplo.

6.7 Limitações

As evidências de melhoria, quando e se coletadas, estarão restritas às perguntas de domínio relacionadas ao modelo metabólico *E. coli core*, selecionadas com apoio de especialistas de domínio. Melhorias observadas para este modelo e domínio específicos não devem ser generalizadas, sem validação adicional, a outros modelos metabólicos em escala genômica ou a outros domínios de aplicação, os quais estão fora do escopo desta pesquisa.

References

[1] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph RAG approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*, 2024.

[2] Shahul Es, Jithin James, Luis Espinosa Anke, and Steven Schockaert. RAGAs: Automated evaluation of retrieval augmented generation. In Nikolaos Aletras and Orphee De Clercq, editors, *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pages 150–158, St. Julians, Malta, March 2024. Association for Computational Linguistics.

[3] Hui Feng, Yuntzu Yin, Emiliano Reynares, and Jay Nanavati. OntologyRAG: Better and faster biomedical code mapping with retrieval-augmented generation (RAG) leveraging ontology knowledge graphs and large language models. In *Proceedings of the Workshop on Knowledge-Enhanced Information Retrieval (KEIR) at ECIR 2025*, 2025. Accepted as a workshop paper.

[4] Rishi Kalra, Zekun Wu, Ayesha Gulley, Airlie Hilliard, Xin Guan, Adriano Koshiyama, and Philip Treleaven. HyPA-RAG: A hybrid parameter adaptive retrieval-augmented generation system for AI legal and policy applications. *arXiv preprint arXiv:2409.09046*, 2024.

[5] Zachary A. King, Colton J. Lloyd, Adam M. Feist, and Bernhard O. Palsson. BiGG models: A platform for integrating, standardizing and sharing genome-scale models. *Nucleic Acids Research*, 44(D1):D515–D522, October 2016.

[6] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474. Curran Associates, Inc., 2020.

[7] Chuanhao Nie, Yunbo Liu, and Chao Wang. AI application in anti-money laundering for sustainable and transparent financial systems. *arXiv preprint arXiv:2512.06240*, 2025.

[8] Paulo Shakarian, Chitta Baral, Gerardo I. Simari, Bowen Xi, and Lahari Pokala. *Neuro Symbolic Reasoning and Learning*. SpringerBriefs in Computer Science. Springer, Cham, 2023.

[9] Kartik Sharma, Peeyush Kumar, and Yunqing Li. OG-RAG: Ontology-grounded for large language models. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 32962–32981, Suzhou, China, 2025. Association for Computational Linguistics.

[10] Nahim Alves de Souza. An ontology-based approach to accelerate the reconstruction of genome-scale metabolic models. Qualifying exam report, Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, Brazil, August 2025. Advisor: Renata Wassermann; Co-advisor: Mariana Galvão Ferrarini.